

期末建模的表现及创新点

陈子卓

2023200151

2025. 12. 25

• 对期中建模的反思：

因错误理解“信息泄露”而提前将“lon”“lat”等关键信息提前删掉→期末使用哈弗辛公式计算样本点到所属聚合中心点距离的距离；

期中数据处理直接删除“客户反馈”等长文本信息→期末使用大语言模型进行情感分析打分；

此外针对第6组提出的“梯户比例”考虑把两位数和三位数转化为汉字、现供热费的缺失值主要来源于该城市本身就不需要暖气供热以及其他同学pre中提出的右拖尾应对Price取对数等情况进行了考虑。

• 期末使用训练模型：

Random Forest、Xgboost、LightGBM

• 模型性能表：

Price	Model	In-sample	Out-sample	CV	Kaggle Score
	Midterm Linear Model	499723.2041	540262.5291	1114245	32.6
	Random Forest	200551.1649	269244.8943	200551.2	74.7
	Xgboost	151746.2398	222273.0621	151746.2	72.1
	LightGBM	332189.3102	340512.6526	332189.3	71.7
Rent	Model	In-sample	Out-sample	CV	Kaggle Score
	Midterm Linear Model	100057.9159	114320.3366	32619.24	32.6
	Random Forest	26305.9527	69493.75877	0.517062	74.7
	Xgboost	64810.74668	78465.476	0.526011	72.1
	LightGBM	83706.89581	89350.9982	0.513971	71.7

创新点分析:

一、Ollama + Phi3:mini 构建的情感分析模块:

1. **Phi3:mini 优势:** 是微软推出的 3.8B 参数轻量级大模型, 兼顾推理效率与情感分析精度。相比大参数量模型, 更适配“房屋优势”“核心卖点”这类房产领域化的短文本的情感分析场景; 相比传统词典法或机器学习分类器, Phi3:mini 通过 Prompt 引导可精准识别, 无需人工标注情感词典

2. **全局缓存机制:** 考虑到房屋文本存在大量重复或相似内容(如“南北通透”“拎包入住”), 基于“任务 + 文本”的哈希键构建全局缓存字典, 结合 JSON 文件持久化, 避免相同文本或任务的重复 LLM 调用, 缓存命中率和处理效率提高

3. **多维度情感特征与输出标准化:** 不仅输出情感类型{positive: 1/negative: -1/neutral: 0}, 还保留置信度confidence (0-1 浮点数) 作为特征权重, 显然高置信度的正面情感对房价预测贡献更高; 标准化的输出结果直接对接后续机器学习模型的数值输入要求, 实现 NLP 特征与传统特征的无缝融合

二、Optuna模块:

1. **分模型设置调参体系:** 随机森林聚焦树结构参数适配其“集成决策树”的特性, 且max_features仅提供sqrt/log2/None等贴合 RF 的选项; XGBoost/LightGBM: 重点优化学习率、正则项、采样率, 且 LightGBM 额外适配num_leaves/min_child_samples等专属参数

2. **贝叶斯搜索策略:** 采用 Optuna 的TPESampler (树结构 Parzen 估计器), 基于历史调参结果自适应优化参数搜索方向, 相比网格搜索、随机搜索, 在相同调参轮数下能更快收敛到最优参数; 学习率、正则项等“小范围精细调整更有效”的参数特性, 启用log=True, 按对数尺度搜索, 避免线性搜索的效率浪费